Autorzy:
Bartosz Świrta
Radosław Radziukiewicz

Na jakie dane będziemy zwracać uwagę?

Ponieważ naszym zadaniem jest skonstruowanie systemu rekomendującego **produkty użytkownikom na podstawie ich sesji**, będziemy potrzebowali danych użytkowników obecnych w systemie sklepu eSzoping, wraz z ich listą intreakcji.

Dane użytkowników

Dane użytkowników zawarte są w pliku **users.jsonl**.

Pojedynczy rekord opisujący użytkownika składa się z następujących kolumn:

- id użytkownika w systemie
- imię użytkownika
- miasto zamieszkania
- adres zamieszkania

Przypuszczalnie, nie wszystkie informacje zawarte w rekordach będą dla nas użyteczne. Dalsza analiza oceni przydatność poszczególnych atrybutów.

Dane produktów

Dane związane z produktami zawarte są w pliku **products.jsonl**.

Pojedynczy rekord opisujący produkt składa się z następujących kolumn:

- id produktu w systemie
- nazwa produktu
- kategoria przynależności produktu
- cena produktu
- ocena produktu

Przypuszczalnie, nie wszystkie informacje zawarte w rekordach będą dla nas użyteczne. Dalsza analiza oceni przydatność poszczególnych atrybutów.

Dane sesji

Dane łączące użytkowników z produktami zawarte są w pliku **sessions.jsonl**. Plik ten zawiera rekordy opisujące aktywności użytkowników w obrębie strony eSzoping.

Pojedynczy rekord opisujący akcję użytkownika w systemie składa się z następujących kolumn:

- id sesji w systemie

- punkt w czasie odbycia się aktywności
- id użytkownika którego dotyczy wydarzenie
- id produktu którego dotyczy wydarzenie
- typ wydarzenia
- informacja o oferowanej zniżce
- id dokonanego zakupu

Aby wydobyć "pełnię" informacji odnośnie sesji, będziemy musieli uwzględnić pliki opisujące **produkty i użytkowników** w analizie danych sesji.

Przypuszczalnie, nie wszystkie informacje zawarte w rekordach będą dla nas użyteczne. Dalsza analiza oceni przydatność poszczególnych atrybutów.

Nieistotne dane

Dane, których nie użyjemy w trakcie analizy, to te zawarte w pliku **deliveries.jsonl**. Plik ten zawiera rekordy opisujące zdarzenia dowozu produktu do kupującego. Zakładamy, iż dane te są nieistotne z punktu widzenia interakcji użytkownika ze sklepem internetowym.

In [ ]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns


# Used for verbose data presentation.
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('max_colwidth', None)

usersDataPath = './data/users.jsonl'
productsDataPath = './data/products.jsonl'
sessionsDataPath = './data/sessions.jsonl'

usersDF = pd.read_json(usersDataPath, lines=True)
sessionsDF = pd.read_json(sessionsDataPath, lines=True)
productsDF = pd.read_json(productsDataPath, lines=True)
```

Analiza samodzielnych danych

Teraz dokładnie przyjrzymy się danym które mogą być analizowane samodzielnie. Zbadamy typy ich atrybutów, rozkłady oraz podejmiemy pierwsze decyzje modelowania danych.

Dane produktów

Aby mieć lepsze "poczucie" analizowanych danych, poniżej prezentujemy 10 pierwszych rekordów obecnych w dostarczonych danych.

In [ ]:
```
productsDF.head(n=10)
```

Out[ ]:

product_id	product_name	category_path	price	user_rating

	product_id	product_name	category_path	price	user_rating
0	1001	Telefon Siemens Gigaset DA310	Telefony i akcesoria;Telefony stacjonarne	58.97	4.740862
1	1002	Kyocera FS-1135MFP	Komputery;Drukarki i skanery;Biurowe urządzenia wielofunkcyjne	2048.50	1.564504
2	1003	Kyocera FS-3640MFP	Komputery;Drukarki i skanery;Biurowe urządzenia wielofunkcyjne	7639.00	3.520694
3	1004	Fallout 3 (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	49.99	4.334193
4	1005	Szalone Króliki Na żywo i w kolorze (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	49.99	4.496124
5	1006	Call of Duty 4 Modern Warfare (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	59.90	0.405119
6	1007	Dead Space 3 (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	89.99	1.889997
7	1008	Tom Clancy's Rainbow Six Vegas (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	49.99	2.097467
8	1009	Kinect Joy Ride (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	69.00	0.304420
9	1010	BioShock 2 (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	89.99	3.894822

Już z tych przykładowych danych możemy wyciągnąć kilka interesujących wniosków. Po pierwsze, ceny produktów mogę w sposób znaczący różnić się między sobą (58.97 kontra 7639.00). Po drugie, ocena produktu może mieć wartość poniżej 1 (przykład z 5 wiersza). Po trzecie, nazwa produktu wydaje się być zbędna w momencie posiadania jego identyfikatora (jest ona po prostu kolejnym unikatowym ciągiem znaków). Po czwarte, i to jest najabrdziej istotny wniosek, kolumna **category_path** zawiera informacją o kategorii produktu w formie "doprecyzowywania" tzn. kategorie rozdzielane są znakiem **;** a najistotniejsza kategoria umieszczona jest na samym początku napisu.

In [ ]:
```
productsDF.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 319 entries, 0 to 318
Data columns (total 5 columns):
 #   Column         Non-Null Count  Dtype  
---  ------         --------------  -----  
 0   product_id     319 non-null    int64  
 1   product_name   319 non-null    object 
 2   category_path  319 non-null    object 
 3   price          319 non-null    float64
 4   user_rating    319 non-null    float64
dtypes: float64(2), int64(1), object(2)
memory usage: 12.6+ KB
```

Widzimy, iż dane produktów nie zawierają żadnych brakujących wartości.

Dane produktów zawierają dwie kolumny o typie napisowym (product_name oraz category_path), jedną o typie całkowitym (product_id) oraz dwie o typie zmiennoprzecinkowym

(price i user_rating).

Identyfikatory produktu

W celu lepszego zaznajomienia się z danymi opisującymi identyfikator produktu dokonujemy dalszej analizy kolumny **product_id**.

In [ ]:
```
print('Max id of the product is: {}'.format(productsDF['product_id'].max()))
print('Min id of the product is: {}'.format(productsDF['product_id'].min()))
print('Disctinct id count is: {}'.format(productsDF['product_id'].nunique()))
```

```
Max id of the product is: 1319
Min id of the product is: 1001
Disctinct id count is: 319
```

Jak widzimy, minimalnym identyfikatorem produktu jest wartość **1001** a maksymalnym wartość **1319**. Ponadto wszystkie wartości pomiędzy **1001 a 1319** są osiągane dokładnie 1 raz.

Nazwy produktu

Następnie analizie poddamy kolumnę opisującą nazwę produktu **product_name**.

In [ ]:
```
print('Distinct name count is: {}'.format(productsDF['product_name'].nunique()))
```

```
Distinct name count is: 319
```

Widzimy, iż w naszych danych nie występują produkty o tych samych nazwach.

Scieżka kategorii

Teraz analizie poddamy kolumnę opisującą scieżkę kategorii produktu **category_path**. W tym celu przyjrzymy się dostępnym ścieżkom kategorii oraz liczności każdej z nich tzn. ile produktów należy do danej ścieżki.

In [ ]:
```
print(productsDF['category_path'].drop_duplicates().reset_index(drop=True).sort_valu
```

```
                                  Gry i konsole;Gry komputerowe
                    Gry i konsole;Gry na konsole;Gry PlayStation3
                        Gry i konsole;Gry na konsole;Gry Xbox 360
   Komputery;Drukarki i skanery;Biurowe urządzenia wielofunkcyjne
                                 Komputery;Monitory;Monitory LCD
                               Komputery;Tablety i akcesoria;Tablety
                                    Sprzęt RTV;Audio;Słuchawki
         Sprzęt RTV;Przenośne audio i video;Odtwarzacze mp3 i mp4
                                Sprzęt RTV;Video;Odtwarzacze DVD
              Sprzęt RTV;Video;Telewizory i akcesoria;Anteny RTV
              Sprzęt RTV;Video;Telewizory i akcesoria;Okulary 3D
Telefony i akcesoria;Akcesoria telefoniczne;Zestawy głośnomówiące
  Telefony i akcesoria;Akcesoria telefoniczne;Zestawy słuchawkowe
                           Telefony i akcesoria;Telefony komórkowe
                         Telefony i akcesoria;Telefony stacjonarne
```

Zauważamy, że ścieżki kategorii tworzą hierarchię. Każda kategoria ma swój korzeń, który jest rozwijany poprzez ewentualne dopisywanie nowych podkategorii.

In [ ]:
```
productsDF.groupby('category_path')['product_id'].count().sort_values(ascending=Fals
```

Out[ ]:
```
category_path
Gry i konsole;Gry komputerowe                                    202
Gry i konsole;Gry na konsole;Gry Xbox 360                         32
Sprzęt RTV;Video;Telewizory i akcesoria;Anteny RTV                30
Komputery;Monitory;Monitory LCD                                   17
Gry i konsole;Gry na konsole;Gry PlayStation3                      9
Komputery;Drukarki i skanery;Biurowe urządzenia wielofunkcyjne     9
Telefony i akcesoria;Akcesoria telefoniczne;Zestawy głośnomówiące  5
Telefony i akcesoria;Akcesoria telefoniczne;Zestawy słuchawkowe    4
Komputery;Tablety i akcesoria;Tablety                              2
Sprzęt RTV;Przenośne audio i video;Odtwarzacze mp3 i mp4           2
Sprzęt RTV;Video;Odtwarzacze DVD                                   2
Telefony i akcesoria;Telefony komórkowe                            2
Sprzęt RTV;Audio;Słuchawki                                         1
Sprzęt RTV;Video;Telewizory i akcesoria;Okulary 3D                 1
Telefony i akcesoria;Telefony stacjonarne                          1
Name: product_id, dtype: int64
```

Powyższy wynik ukazuje nam, że liczba produktów w kategoriach nie jest rozłożona w sposób równomierny. Niektóre kategorie posiadają jedynie jeden zakwalifikowany produkt, podczas gdy inne zawierają ich aż kilkadziesiąt lub kilkaset. Proponowanym rozwiązaniem będzie zmieniejszenie liczby dostępnych kategorii poprzez rzutowanie danych na odpowiedni korzeń hierarchi kategorii.

Poprzez rzutowanie moglibyśmy otrzymać następujące wyniki:

- "Gry komputerowe": 202
- "Gry na konsole": 41 (Xbox and PS3)
- "Sprzęt RTV": 36
- "Komputery": 28
- "Telefony i akcesoria": 12

Liczba i liczność wytworzonych kategorii wydaje się być zadowalająca na ten moment.

In [ ]:
```
separator = ';'
newGroups = ['Gry komputerowe', 'Gry na konsole', 'Sprzęt RTV', 'Komputery', 'Telefo

def castCategoryPath(categoryPath):
    categories = categoryPath.split(separator)
    foundGroups = [group for group in newGroups if group in categories]
    if len(foundGroups) != 1:
        raise RuntimeError('wrong group cast: {}'.format(foundGroups))
    return foundGroups[0]

transformed = productsDF['category_path'].apply(castCategoryPath)
print(transformed.value_counts())
```

```
Gry komputerowe         202
Gry na konsole           41
Sprzęt RTV               36
Komputery                28
Telefony i akcesoria     12
Name: category_path, dtype: int64
```

Cena produktu

Poniżej przedstawiamy histogram prezentujący rozkład wartości cen zawartych w kolumnie **price**.

In [ ]:
```
print('Max price is: {}'.format(productsDF['price'].max()))
print('Min price is: {}'.format(productsDF['price'].min()))

sns.displot(data=productsDF, x="price", kind="kde")
```

```
Max price is: 7639.0
Min price is: 1.0
```

Out[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1eb8f58b940>
```

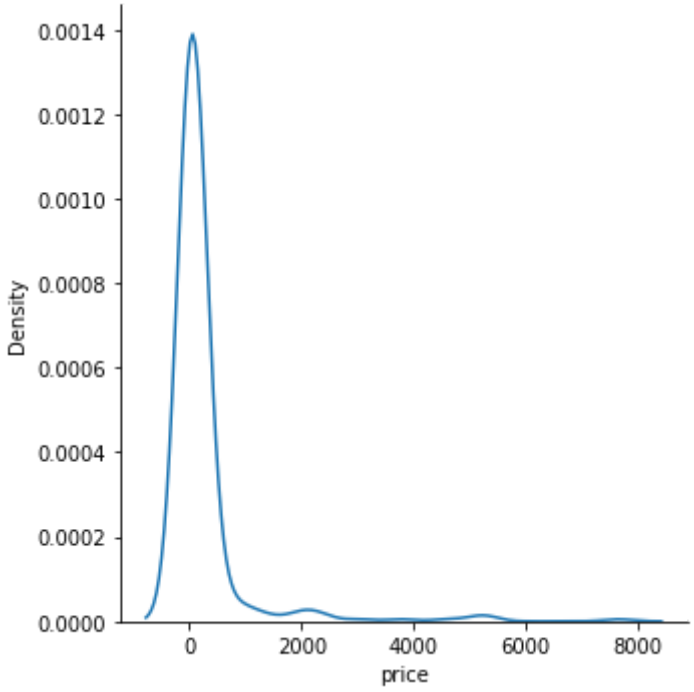

In [ ]:
```
sns.violinplot(data=productsDF, x='price')
```

Out[ ]:
```
<AxesSubplot:xlabel='price'>
```

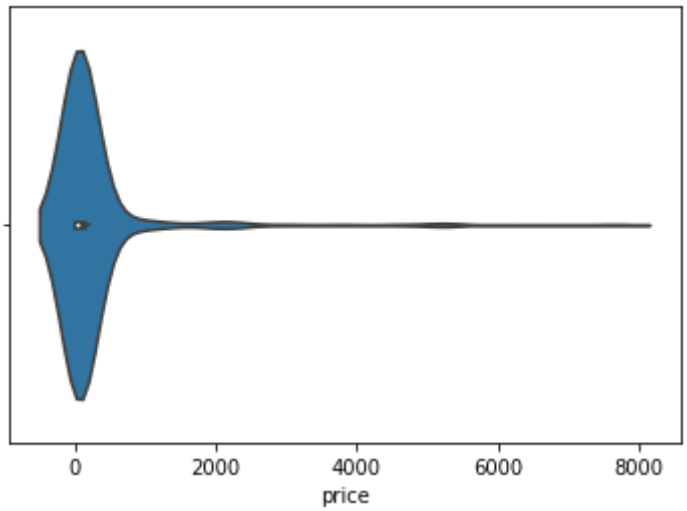

Widzimy, że zdecydowana większość cen mieści się w poniżej kwoty 100. Niestety, wartości odstające zakłócają wygląd wykresów. Decydujemy się rozbić produkty na tańsze i droższe. Jak punkt podziału przyjmujemy wartość 100.

In [ ]:
```
threshold = 100

cheapProducts = (productsDF.loc[productsDF['price'] < threshold], 'Cheap')
expensiveProducts = (productsDF.loc[productsDF['price'] >= threshold], 'Expensie')
```

```
productsSplit = [cheapProducts, expensiveProducts]

for ps in productsSplit:
    print('{} products amount is: {}'.format(ps[1], ps[0]['price'].count()))
    sns.displot(data=ps[0], x="price", kind="kde")
```

```
Cheap products amount is: 247
Expensie products amount is: 72
```

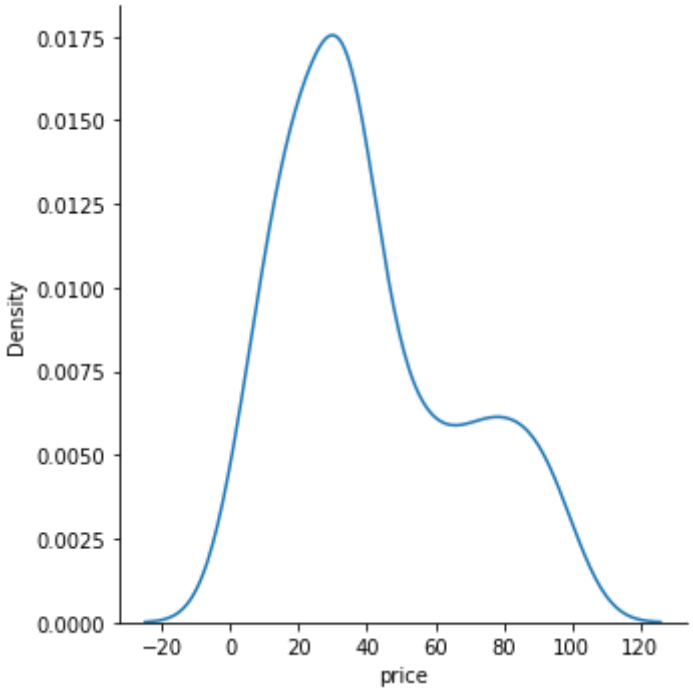

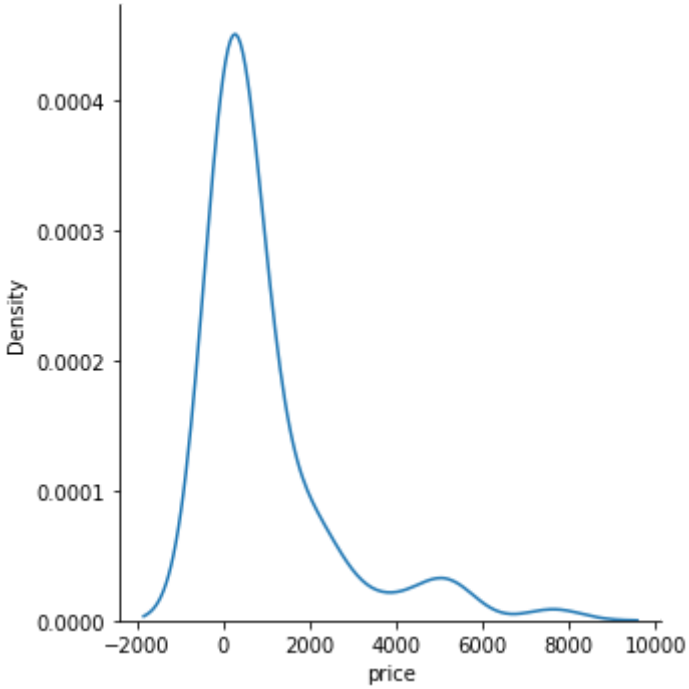

Jak widzimy, wartości zmiennej opisującej ceny produktu nie są rozłożone w sposób równomierny. Przypominają jednak złożenia kilku rozkładów normalnych których wartości oczekiwane i wariancje są różne. Interesujące wydają nam się również produkty z ceną 1.0. Postanawiamy przyjrzeć się rekordom z taką ceną.

In [ ]:
```
productsDF.loc[productsDF["price"] == productsDF["price"].min()]
```

Out[ ]:

product_id	product_name	category_path	price	user_rating

	product_id	product_name	category_path	price	user_rating
140	1141	Król Futbolu Piłkarski Quiz (PC)	Gry i konsole;Gry komputerowe	1.0	3.462897
192	1193	Heroes Over Europe (PC)	Gry i konsole;Gry komputerowe	1.0	4.549431
271	1272	The Ball (PC)	Gry i konsole;Gry komputerowe	1.0	2.286441

Powyższe pozycje choć zastanawiające są możliwe. W celu weryfikacji poparwności tych danych konieczne jest zapytanie przedstawiciela firmy eSzoping.

Ocena produktu

Poniżej prezentujemy wykres opisujący rozkład wartości zmiennych opisujących opinie o produkcie zawartych w kolumnie **user_rating**.

In [ ]:
```
print('Max rating is: {}'.format(productsDF['user_rating'].max()))
print('Min rating is: {}'.format(productsDF['user_rating'].min()))

sns.displot(data=productsDF, x='user_rating', kind='kde')
```

```
Max rating is: 4.993596217584222
Min rating is: 0.013904725430070002
<seaborn.axisgrid.FacetGrid at 0x1eb9100ed00>
```

Out[ ]:

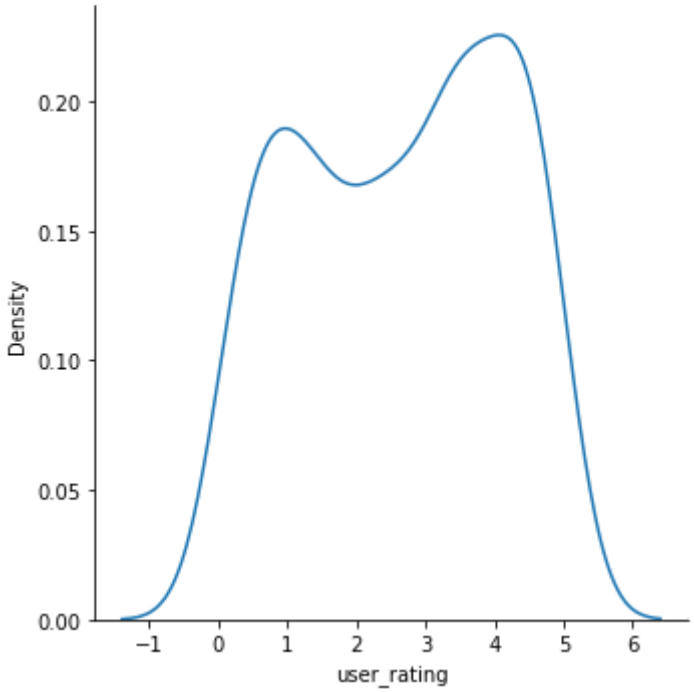

Jak widać, opinie o produktach rozłożone są w sposób bardziej równomierny niż ceny produktów. Ponadto, wszystkie wartości z kolumny **user_rating** zawarte są w przedziale (0,5).

Dane użytkowników

Podobnie jak w przypadku analizy danych o produktach, przyjrzyjmy się przykładowym wpisom w dostępnych danych:

In [ ]:
```
usersDF.head(n=10)
```

Out[ ]:

	user_id	name	city	street
0	102	Angelika Gasik	Warszawa	al. Kamienna 87
1	103	Jakub Nickel	Szczecin	ul. Szpitalna 638
2	104	Emil Żuchowicz	Poznań	ulica Dolna 26
3	105	Gustaw Pośnik	Wrocław	ul. Osiedlowa 23/03
4	106	Sylwia Chuchla	Gdynia	aleja Krakowska 84/76
5	107	Grzegorz Machoń	Kraków	aleja Olchowa 28/90
6	108	Artur Doktor	Szczecin	pl. Handlowa 69/04
7	109	Nikodem Pyć	Radom	pl. Wojska Polskiego 404
8	110	Krystian Lesner	Szczecin	pl. Liliowa 708
9	111	Klara Szumiec	Gdynia	aleja Grabowa 92

Widzimy, że praktycznie wszystkie kolumny posiadają typ napisowy (**name, city, street**). Ponadto, kolumna **street** w rzeczywistości zawiera adres użykownika, a nie ulicę na której mieszka. Pozostałe kolumny wydają się być standardowe w kontekście zawieranych danych.

In [ ]:
```
usersDF.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 4 columns):
 #   Column   Non-Null Count  Dtype 
---  ------   --------------  ----- 
 0   user_id  200 non-null    int64 
 1   name     200 non-null    object
 2   city     200 non-null    object
 3   street   200 non-null    object
dtypes: int64(1), object(3)
memory usage: 6.4+ KB
```

Widzimy, że dane użytkowników nie zawierają żadnych brakujących wartości. Wszystkie wpisy są kompletne.

Identyfikator użytkownika

Teraz przyjrzymy się wartościom zawartym w kolumnie **user_id**. Interesuje nas, czy wszystkie wartości są unikalne. Ponadto dobrze byłoby znać zakres identyfikatorów, oraz czy jest on w pełni zapełniony.

In [ ]:
```
print('Max user id is: {}'.format(usersDF['user_id'].max()))
print('Min user id is: {}'.format(usersDF['user_id'].min()))
print('Unique identifiers number is: {}'.format(usersDF['user_id'].nunique()))
```

```
Max user id is: 301
Min user id is: 102
Unique identifiers number is: 200
```

Z powyższych wyników wnioskujemy, że zakres identyfikatorów wynosi [102, 301] Ponadto, każda wartość w tym zakresie przyjmowana jest dokładnie jeden raz.

Imię użytkownika

Następną kolumną, jaką poddamy dalszej analizie, jest ta zawierająca informacje o imieniu użytkownika. Jesteśmy zainteresowani, czy w dostępnych danych istnieje duplikacja użytkownika (różne identyfikatory ale to samo imię i nazwisko).

In [ ]:
```
print('Unique name count is: {}'.format(usersDF['name'].nunique()))
```

```
Unique name count is: 200
```

Jak widać, wszystkie imiona użytkowników są unikatowe. Dzięki temu, jesteśmy w stanie stwierdzić, że w zbiorze danych nie występują potencjalne anomalie. Poza tym zakładamy, że kolumna o nazwie **name** nie wnosi żadnych nowych informacji do modelu i rozwiązywanego zagadnienia.

Miasto zamieszkania

Kolumna zawierająca miasto zamieszkania użytkownika (zakładamy, że jest to miejsce zamieszkania, jednak nie mamy tutaj żadnej pewności co do tego) wydaje się nieść potencjalnie wiele przydatnych informacji. Przede wszystkim dzięki niej jesteśmy w stanie stwierdzić, czy zbiór użytkowników na których operujemy, jest reprezentatywny. Ponadto potencjalnie może zachodzić korelacja pomiędzy miastem zamieszkania a zainteresowaniem pewnymi produktami przez użytkowników. Poniżej prezentujemy histogram z uzyskanymi wynikami.

In [ ]:
```
sns.catplot(data=usersDF, kind='count', x='city', height=8)
```

Out[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1eb903bc250>
```

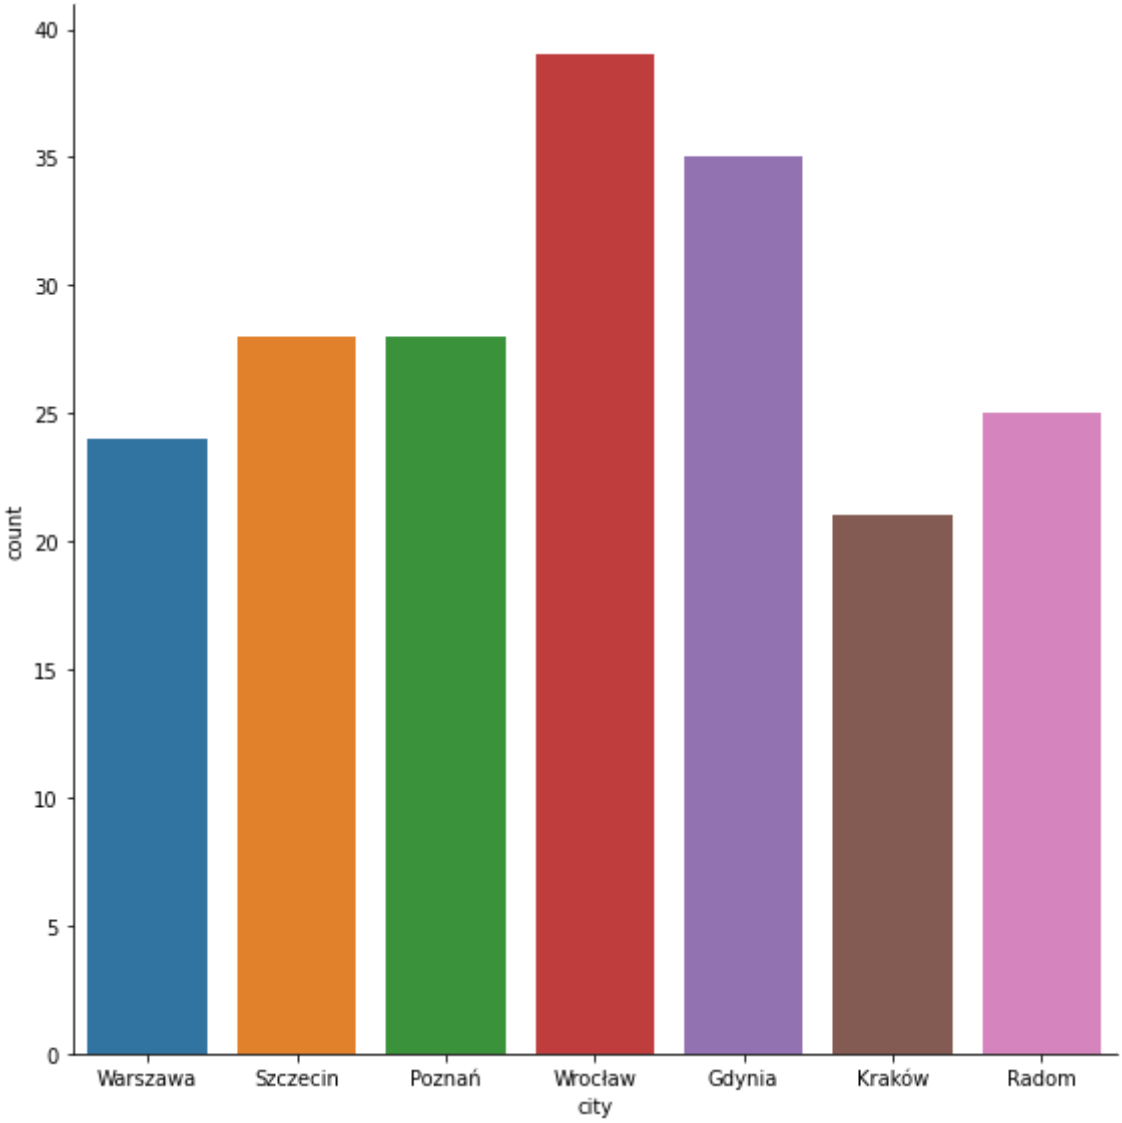

Z powyższego histogramu widzimy, iż pomimo pewnych nieregularności, dane są rozłożone dość równomiernie. Dzięki temu, jesteśmy w stanie stwierdzić, że dane na których pracujemy, są reprezentatywne

Adres zamieszkania

Ostatnią kolumną do przeanalizowania jest ta zawierająca dane o adresach zamieszkania użytkowników. Zakładamy, iż prawdopodobnie kolumna to nie będzie dla nas w żaden sposób informatywna. Tym nie mniej, jesteśmy zainteresowani, czy w danych nie występuje duplikacja adresu.

In [ ]:
```
print('Unique address count is: {}'.format(usersDF['street'].nunique()))
```

```
Unique address count is: 200
```

Jak widać, wszystkie adresu są unikatowe.

Dane sesji

Przyjrzyjmy się nieco bliżej danym sesji.

In [ ]:
```
sessionsDF.head(10)
```

Out[ ]:

	session_id	timestamp	user_id	product_id	event_type	offered_discount	purchase_id
0	124	2021-05-13 06:07:09	102	1317	VIEW_PRODUCT	0	NaN
1	125	2021-09-11 01:25:08	102	1170	VIEW_PRODUCT	0	NaN
2	125	2021-09-11 01:29:38	102	1055	VIEW_PRODUCT	0	NaN
3	125	2021-09-11 01:30:44	102	1053	VIEW_PRODUCT	0	NaN
4	125	2021-09-11 01:33:50	102	1060	VIEW_PRODUCT	0	NaN
5	125	2021-09-11 01:38:20	102	1048	VIEW_PRODUCT	0	NaN
6	125	2021-09-11 01:39:58	102	1011	VIEW_PRODUCT	0	NaN
7	125	2021-09-11 01:44:10	102	1098	VIEW_PRODUCT	0	NaN
8	125	2021-09-11 01:47:32	102	1055	VIEW_PRODUCT	0	NaN
9	125	2021-09-11 01:52:05	102	1053	VIEW_PRODUCT	0	NaN

Widzimy, że dane sesji nie zawierają bezpośrednio informacji o użytkownikach i produktach, a jedynie ich unikalne identyfikatory. Stwierdzamy, iż w celu dokonania lepszej analizy powinniśmy dołączyć do danych sesji odpowiadające dane z tabeli o użytkownikach i produktach.

W tej sekcji postanowiliśmy odpowiedzieć sobie na kilka pytań istotnych z punktu widzenia zadania:

- Czy istnieje użytkownik nie posiadający żadnej sesji?
- Czy istnieje produkt, który nie został przez nikogo wyświetlony?
- Czy dane użytkowników i produktów są pełne, tj. czy w danych sesji jest produkt bądź użytkownik, który nie widnieje w innych dostarczonych danych.

Przy łączeniu danych wykorzystaliśmy **outer join** by wszelkie braki w danych były proste do wychwycenia.

In [ ]:

```
# Use outer join in order to keep all values from data frames.
mergedDF = pd.merge(sessionsDF, usersDF, how='outer', on='user_id')
mergedDF = pd.merge(mergedDF, productsDF, how='outer', on='product_id')

print(sessionsDF.shape[0] == mergedDF.shape[0])
mergedDF.info()
```

```
True
<class 'pandas.core.frame.DataFrame'>
Int64Index: 125146 entries, 0 to 125145
Data columns (total 14 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   session_id        125146 non-null  int64
```

```
 1   timestamp         125146 non-null  datetime64[ns]
 2   user_id           125146 non-null  int64
 3   product_id        125146 non-null  int64
 4   event_type        125146 non-null  object
 5   offered_discount  125146 non-null  int64
 6   purchase_id       10893 non-null   float64
 7   name              125146 non-null  object
 8   city              125146 non-null  object
 9   street            125146 non-null  object
 10  product_name      125146 non-null  object
 11  category_path     125146 non-null  object
 12  price             125146 non-null  float64
 13  user_rating       125146 non-null  float64
dtypes: datetime64[ns](1), float64(3), int64(4), object(6)
memory usage: 14.3+ MB
```

Stwierdzamy, iż dane nie zawierają anomali (brak nieznanych użytkowników i produktów). Dodatkowo obserwujemy, że użytkownicy częściej przeglądają produkty, niż je kupują. Stosunek obu rodzajów aktywności wynosi 114253:10893.

Obszary którym przyjrzymy się nieco dokładniej w dalszej części:

- session_id - stwierdzenie liczby unikalnych sesji, sprawdzenie czy nie występują błędne dane (np. ujemne identyfikatory)
- timestamp - sprawdzenie przedziału czasu z jakiego pochodzą dane
- analiza danych sesji - jakie są najpopularniejsze kategorie, produkty itp.
- gęstość macierzy interakcji

ID sesji

Poszukujemy błędów w atrybucie **session_id**, takich jak wartości ujemne czy duplikacja.

In [ ]:
```
print(f"Minimum session id: {sessionsDF['session_id'].min()}")
print(f"Maximum session id: {sessionsDF['session_id'].max()}")
print(f"Number of unique sessions: {sessionsDF['session_id'].nunique()}")
```

```
Minimum session id: 124
Maximum session id: 21382
Number of unique sessions: 21259
```

Wartości w kolumnie **session_id** są poprawne. Liczba 21259 unikalnych sesji jest również pokaźnym zbiorem danych.

Sprawdzenie przedziału czasowego

Dla naszego problemu istotne jest sprawdzenie czy dane pochodzą z odpowiednio długiego okresu. Uważamy, że minimalny przedział pokryty przez dane powinien wynosić 1 rok. Dodatkowo, zweryfikujemy czy okres pokryty jest w całości (tzn. czy nie występują okresy z brakiem danych).

In [ ]:
```
byDaySessionsDF = sessionsDF.groupby(pd.Grouper(key='timestamp', axis=0, freq='1D',
print(f"Days count in data: {byDaySessionsDF.size().count()}")
print(f"first date: {byDaySessionsDF.count().head(1)}\nlast date: {byDaySessionsDF.c
```

```
Days count in data: 300
first date:            session_id  user_id  product_id  event_type  offered_discoun
t  \
timestamp
```

```
2021-01-01         431      431         431         431                431

            purchase_id
timestamp
2021-01-01           36
last date:             session_id  user_id  product_id  event_type  offered_discount
\
timestamp
2021-10-27         304      304         304         304                304

            purchase_id
timestamp
2021-10-27           23
```

Dane pochodzą z 10 miesięcy, a dokładnie z okresu od **01.01.2021 do 27.10.2021**, w danych nie występują przerwy. Oznacza to, że dane nie pokrywają okresu świątecznego, który jest istotnym czasem z punkty widzenia modelowania na potrzeby sklepu internetowego.

Zamierzamy skontaktować się z reprezentantem firmy eSzoping w celu pozyskania zbioru danych z brakującego przedziału czasowego.

Popularność produktów i kategorii

Poniżej sprawdzamy jak często każdy z produktów występuję w danych. Można rozumieć to jako analizę "popularności" produktów w sklepie.

In [ ]:
```
sns.catplot(data=sessionsDF, kind='count', x='product_id', height=8)
```

Out[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1ebfeee2b50>
```

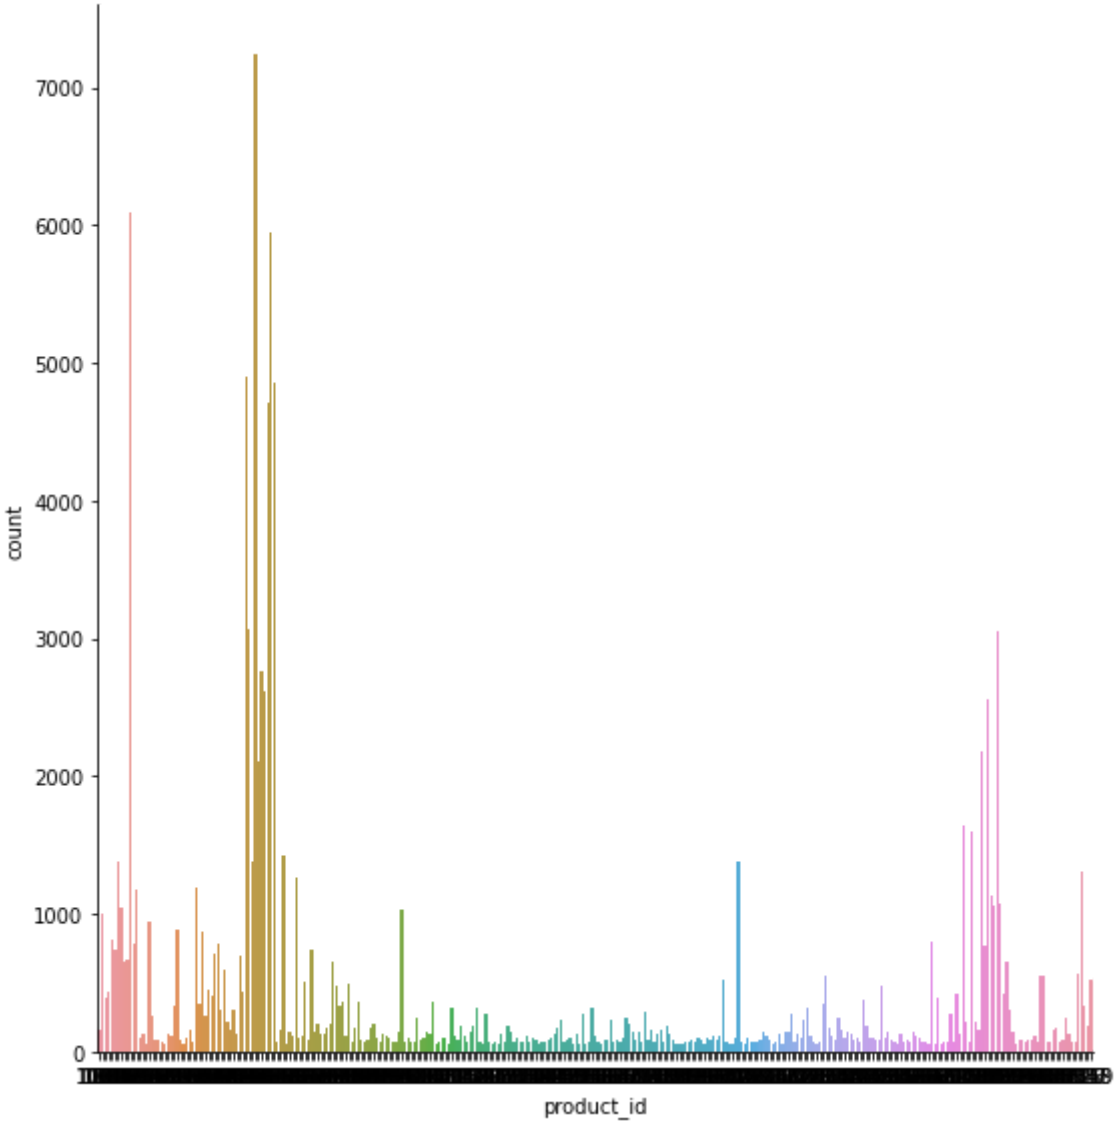

Jak widać, w częstości interakcji z produktami istnieje duża dysproporcja. Widzimy, że jedynie niewielki odsetek produktów przyciąga znaczną uwagę użytkowników, podczas gdy większość produktów nie budzi większego zainteresowanie.

Co istotne, każdy z produktów został obejrzany przez choć jednego użytkownika. Minimalna liczba interakcji wynosi 52.

Zainteresowało nas, jakie dokładnie produkty są najpopularniejsze i do jakich kategorii należą. Za poziom odcięcia przyjęliśmy 95 percentyl.

In [ ]:

```
subSessionDF = sessionsDF.groupby('product_id').filter(lambda x : len(x) > sessionsD
subSessionProductDF = pd.merge(subSessionDF, productsDF, how='inner', on='product_id
sns.catplot(data=subSessionProductDF, kind='count', x='product_name', height=8, aspe
plt.xticks(rotation=90) # Rotate labels to make plot more readable

sns.catplot(data=subSessionProductDF, kind='count', x='category_path', height=8, asp
topProductsDF = productsDF.loc[productsDF['product_id'].isin(subSessionDF['product_i
print(topProductsDF['user_rating'].agg(['count', 'mean', 'max', 'min']))
topProductsDF
```

```
count    16.000000
mean      2.909632
max       4.877668
min       0.131420
Name: user_rating, dtype: float64
```

Out[ ]:

	product_id	product_name	category_path	price	user_rating
10	1011	BioShock Infinite (Xbox 360)	Gry i konsole;Gry na konsole;Gry Xbox 360	139.99	4.429294
47	1048	Gra o tron (PC)	Gry i konsole;Gry komputerowe	63.49	0.131420
48	1049	Max Payne 3 (PC)	Gry i konsole;Gry komputerowe	17.90	0.769084
50	1051	Spec Ops The Line (PC)	Gry i konsole;Gry komputerowe	76.90	4.424979
51	1052	Duke Nukem Forever (PC)	Gry i konsole;Gry komputerowe	78.90	0.684426
52	1053	Anno 2070 (PC)	Gry i konsole;Gry komputerowe	42.90	3.553721
53	1054	Call of Duty 2 (PC)	Gry i konsole;Gry komputerowe	32.99	2.468547
54	1055	Call of Duty Modern Warfare 3 (PC)	Gry i konsole;Gry komputerowe	32.99	4.333934
55	1056	Call of Duty Black Ops (PC)	Gry i konsole;Gry komputerowe	29.99	2.062100
56	1057	Doom 3 (PC)	Gry i konsole;Gry komputerowe	19.99	3.835961
59	1060	Wiedźmin 2 Zabójcy królów (PC)	Gry i konsole;Gry komputerowe	34.99	2.334113
277	1278	Intenso Music Walker 8GB	Sprzęt RTV;Przenośne audio i video;Odtwarzacze mp3 i mp4	78.90	2.428217
280	1281	Manta MM266	Sprzęt RTV;Przenośne audio i video;Odtwarzacze mp3 i mp4	64.80	4.843806
283	1284	Opticum AX-900	Sprzęt RTV;Video;Telewizory i akcesoria;Anteny RTV	49.90	0.915083
285	1286	Opticum AX-1000	Sprzęt RTV;Video;Telewizory i akcesoria;Anteny RTV	59.99	4.877668
288	1289	Philips SDV5225	Sprzęt RTV;Video;Telewizory i akcesoria;Anteny RTV	129.00	4.461759

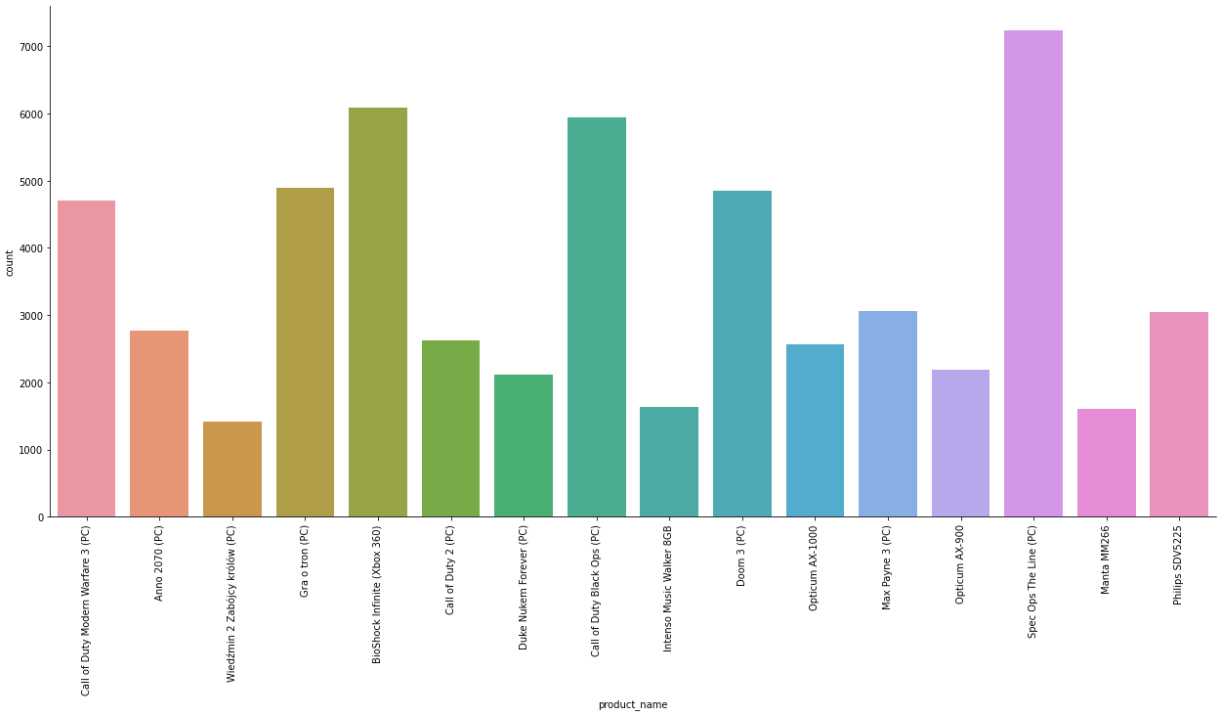

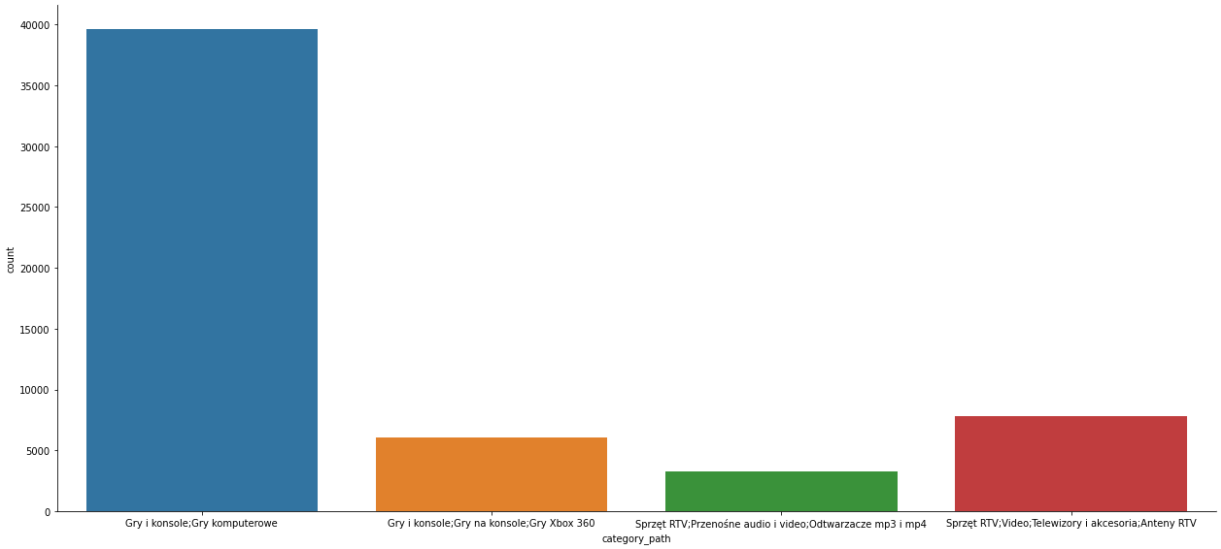

Okazuje się, że najpopularniejszymi produktami w sklepie są **Gry komputerowe**. Co ciekawe, drugą najczęściej występującą kategorią są **Anteny RTV**.

Bardzo popularne okazały się produkty o bardzo niskiej ocenie np. **Gra o tron (PC)**: ~5000 interakcji, ocena ~0.1.

Wśród 16 najpopularniejszych produktów średnia ocena wynosi ~2.9 .

Spojrzymy teraz całościowo na sesje i przeanalizujemy jakie są najczęściej oglądane i kupowane kategorie produktów. Ze względu, że "pełna kategoria" wprowadza zbyt dużą gradację, na potrzeby tej analizy kategorie zostały zredukowane do 5 (zaproponowanych wcześniej podczas analizy atrybutu **category_path**).

Dane sesji podzieliśmy na dwa rozłączne podzbiory, w jednym znajdują się tylko obejrzane produkty, w drugim tylko produkty kupione (**event_type** odpowiednio **VIEW_PRODUCT** i **BUY_PRODUCT**).

In [ ]:
```
sessionProductDF = pd.merge(sessionsDF, productsDF, how='inner', on='product_id')
noBuySessions = sessionProductDF.loc[sessionProductDF['event_type'] == 'VIEW_PRODUCT
buySessions = sessionProductDF.loc[sessionProductDF['event_type'] == 'BUY_PRODUCT'].

# Reduce the number of product categories
noBuySessions['category_path'] = noBuySessions['category_path'].apply(castCategoryPa
buySessions['category_path'] = buySessions['category_path'].apply(castCategoryPath)

sns.catplot(data=noBuySessions, kind='count', x='category_path', height=8)
plt.title("Sessions with no buy action")

sns.catplot(data=buySessions, kind='count', x='category_path', height=8)
plt.title("Sessions with buy action")
```

Out[ ]:
```
Text(0.5, 1.0, 'Sessions with buy action')
```

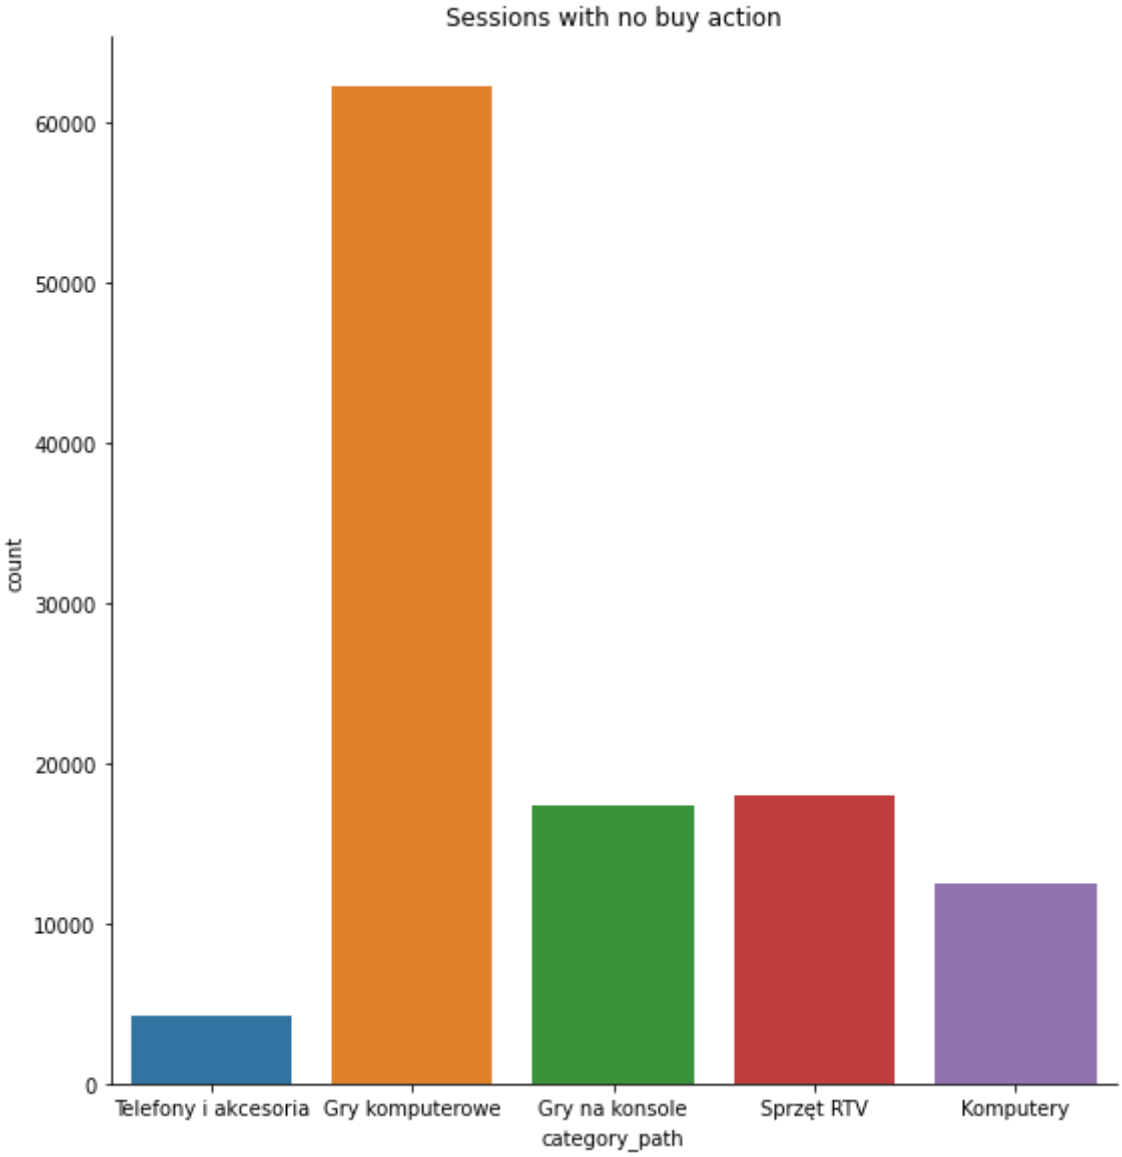
Sessions with no buy action
count
60000
50000
40000
30000
20000
10000
0
Telefony i akcesoria
Gry komputerowe
Gry na konsole
Sprzęt RTV
Komputery
category_path

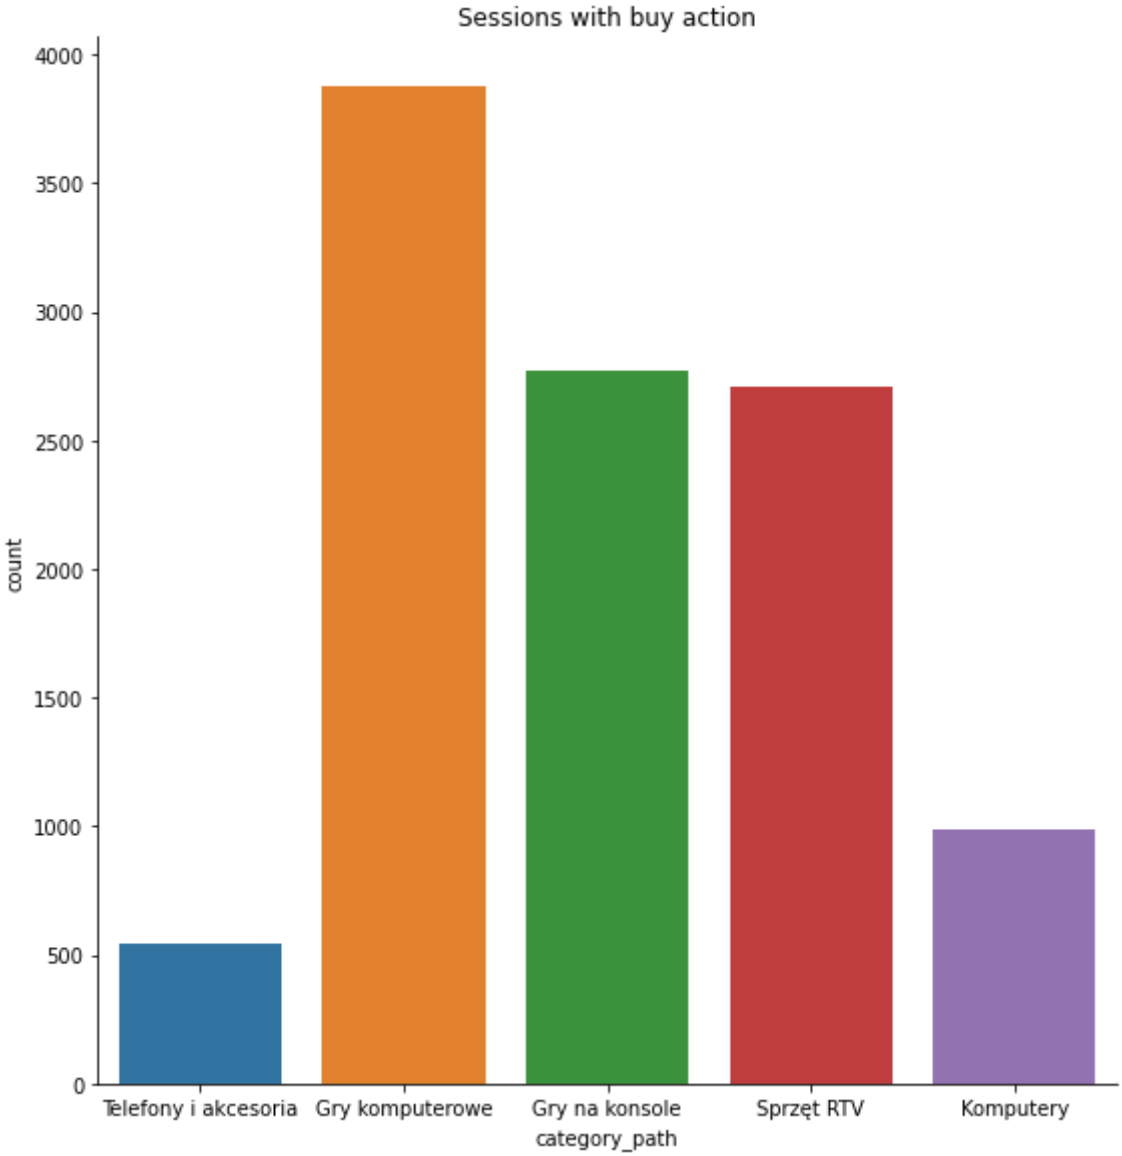

Jak widzimy, zarówno najczęściej oglądaną kategorią jak i najchętniej kupowaną są **Gry komputerowe**. Następnie praktycznie na równej pozycji znajdują się **Gry na konsole** i **Sprzęt RTV**. Na trzeciej pozycji znajdziemy kategorię **Komputery** i najmniej popularna kategoria to **Telefony i akcesoria**.

Zauważamy, że liczba interakcji względem grupy jest bezpośrednio skorelowana z licznością tej grupy.

Współczynnik informacji wzajemnej

Informacyjność danych jest istotna dla każdego problemu modelowania. Dla nas szczególnie istotne jest sprawdzenie, czy istnieje jakiś związek pomiędzy użytkownikiem, a przeglądanymi produktami.

Skalę makroskopową, tzn. czy użytkownik posiada jakieś indywidualne preferencje, możemy sprawdzić licząc współczynnik informacji wzajemnej dla atrybuty **user_id** i **category_path**. Współczynnik policzyliśmy dla czterech formatów danych:

- sesje oglądania produktu, ścieżka kategorii zrzutowana do 5 kategorii głównych
- sesje oglądania produktu, pełna ścieżka kategorii
- sesje kupowania produktu, ścieżka kategorii zrzutowana do 5 kategorii głównych

- sesje kupwoania produktu, pełna ścieżka kategorii

In [ ]:
```
from sklearn import metrics

noBuySessionProductDF = sessionProductDF.drop(sessionProductDF.index[sessionProductD
buySessionProductDF = sessionProductDF.dropna(subset=['purchase_id']).copy()

castNoBuySessionProductDF = noBuySessionProductDF.copy()
castNoBuySessionProductDF['category_path'] = noBuySessionProductDF['category_path'].

castBuySessionProductDF = buySessionProductDF.copy()
castBuySessionProductDF['category_path'] = buySessionProductDF['category_path'].appl


print(f"Mutual information score for user_id and casted category_path (view events):
print(f"Mutual information score for user_id and category_path (view events): {metri

print(f"Mutual information score for user_id and casted category_path (buy events):
print(f"Mutual information score for user_id and category_path (buy events): {metric
```

```
Mutual information score for user_id and casted category_path (view events): 0.01201
7914592724614
Mutual information score for user_id and category_path (view events): 0.033864618320
79142
Mutual information score for user_id and casted category_path (buy events): 0.036659
65936153716
Mutual information score for user_id and category_path (buy events): 0.1202925432618
4302
```

Wyznaczony współczynnik informacji wzajemnej ma bardzo niską wartość. Tylko jeden współczynnik ma wartość powyżej 0.1 i wynosi on ~0.12. Co ciekawe, okazuje się on być wyższy dla bardziej szczegółowych kategorii.

W obliczu tego rozczarowania postanowiliśmy sprawdzić czy może w danych zachodzi korelacja dla innej pary atrybutów. Naszym pomysłem było sprawdzenie czy istnieje zależność między ilością interakcji (popularnością)
z produktem a jego oceną. Tym razem ze względu na ciągłość atyrbutów i chęć wychwycenia bardziej liniowej zależności, policzyliśmy korelację liniową.
Podobnie jak wcześniej policzyliśmy ją oddzielnie dla sesji przeglądania i zakupowych.

In [ ]:
```
noBuySessionProductDF['user_rating'] = noBuySessionProductDF['user_rating'].apply(la
noBuyProdCountSeries = noBuySessionProductDF.groupby(['product_id'])['user_id'].coun
noBuyRatingSeries = noBuySessionProductDF.groupby(['product_id'])['user_rating'].uni
noBuyRatingSeries = noBuyRatingSeries.apply(lambda x : x[0])
print(f"Linear correlation between popularity of a product and user_rating (view eve

buySessionProductDF['user_rating'] = buySessionProductDF['user_rating'].apply(lambda
buyProdCountSeries = buySessionProductDF.groupby(['product_id'])['user_id'].count().
buyRatingSeries = buySessionProductDF.groupby(['product_id'])['user_rating'].unique(
buyRatingSeries = buyRatingSeries.apply(lambda x : x[0])
print(f"Linear correlation between popularity of a product and user_rating (buy even
```

```
Linear correlation between popularity of a product and user_rating (view events): 0.
05366616059079891
Linear correlation between popularity of a product and user_rating (buy events): 0.2
1524332008730712
```

Okazuje się, że i wtym wypadku obserwujemy dość słabą korelację. Dla zdarzeń przglądania jest ona bliska zeru. Wyniki powyższych dwóch ekperymentów zdają się sugerować jakiś problem z

otrzymanymi danymi. Brakuje w nich spodziewanych/istotnych dla zadania zależności.

Postanowiliśmy jeszcze sprawdzić czy zachodzi korelacja liniowa pomiędzy ilością interakcji (popularnością) z danym produktem a jego ceną. Jak wcześniej współczynnik, policzyliśmy niezależenie dla sesji przegladania i zakupowych.

In [ ]:
```
noBuyPriceSeries = noBuySessionProductDF.groupby(['product_id'])['price'].unique().c
noBuyPriceSeries = noBuyPriceSeries.apply(lambda x : x[0])
print(f"Linear correlation between popularity of a product and price (view events):

buyPriceSeries = buySessionProductDF.groupby(['product_id'])['price'].unique().copy(
buyPriceSeries = buyPriceSeries.apply(lambda x : x[0])
print(f"Linear correlation between popularity of a product and price (buy events): {
```

```
Linear correlation between popularity of a product and price (view events): 0.006326
9009916432665
Linear correlation between popularity of a product and price (buy events): 0.0581567
50693072946
```

Wyznaczone współczynniki ponownie są bliskie zeru.

Badanie gęstości macierzy interakcji

Postanowiliśmy sprawdzić również jak wyglada gęstość otrzymanych danych dla zadania predykcji. Utworzyliśmy macierz, której kolumny odpowiadają wszystkim produktom w ofercie, a wiersze poszczególnym użytkonikom.
Jeżeli użytkownik wszedł w interakcje z danym produktem (obejrzał go lub kupił), w odpowidającej komórce będzie 1, w przeciwnym wypadku komórka pozostanie pusta. Dla tak utworzonej macierzy policzyliśmy gęstość.

In [ ]:
```
df = sessionsDF.drop(columns=["session_id", "timestamp", "event_type", "offered_disc
df["hit"] = 1
heatMapDF = pd.pivot_table(df, index="user_id", columns="product_id", values="hit")
print("Sparse matrix density: " + str((heatMapDF.size - heatMapDF.isna().sum().sum()
```

```
Sparse matrix density: 0.47782131661442007
```

Gęstość powyższej macierzy wynosi ~47,8% co jest wartością wystarczającą dla zadania rekomendacji.

Podsumowanie

Podsumowując powyższą analizę:

- W dostarczonych danych nie wykryto oczywistych błędów, takich jak: braki wartości, błędne wartości atrybutów. Jedyne co zwróciło naszą uwagę to trzy produkty, których koszt wynosi 1.
- Dostarczone dane pochodzą z okresu 10 miesięcy. Wydaje nam się, że jest to zbyt krótki przedział czasowy (pomija on okres świąteczny). Właścicieli sklepu eSzoping poprosilibyśmy o udostępnienie danych z szerszego przedziału czasu.
- Kategorie produktów są bardzo nierównomierne. Nawet po zredukowaniu ilości grup do 5 najgorszy współczynnik niezbalansowania wynosi ~1:14. Możemy próbować temu zaradzić rozbijając kategorię większosciową (Gry komputerowe), na mniejsze np. na gatunki gier.

- W danych zachodzi również duża nierównomierność w popularności produktów mierzonej jako liczba interakcji. Podobnie sytuacja wygląda z kategoriami, widzimy bezpośrednią korelację między liczebnością grupy (zredukowanej), a jej popularnością.
- Współczynnik informacji wzajemnej między *user_id*, a *category_path* pokazał, że użytkownicy nie wydają się mieć z góry określony preferencji.
- Współczynniki korelacji liniowej dla ilości interakcji z danym produktem, a jego oceną są bliskie zeru, podobnie jak dla współczynnika między ilością interakcji, a ceną produkty.
- Policzone współczynniki sugerują brak spodziewanych zależności, które w naszej ocenie są kluczowe z punktu widzenia zadania rekomendacji. Na tym etapie domagalibyśmy się nowych danych.
- Sprawdziliśmy również jak wygląda gestość macierzy interakcji, kluczowy wskaźnik dla problemu rekomendacji - nie budzi on żadnych zastrzeżeń.